

Vérie 2 STT 5100

Exercice 1

Observations: $(x_i, Y_i)_{i=1, \dots, n}$

Modèle: $Y_i = \alpha + x_i \beta + \varepsilon_i$

$$\begin{cases} E[\varepsilon_i] = 0 \\ \text{Var}[\varepsilon_i] = \sigma^2 \\ \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \\ i \neq j \end{cases}$$

Question: Meilleur estimateur linéaire non biaisé de α

Étapes: Soit $\hat{\alpha}$ un tel estimateur

① Estimateur linéaire $\rightarrow \hat{\alpha} = \sum_{i=1}^n a_i Y_i$

② Estimateur non biaisé en α

$$E[\hat{\alpha}] = \alpha$$

③ Meilleur estimateur \rightarrow estimateur de variance minimale
(de plus petite variance parmi tous les estimateurs linéaires en α).

Subtilité: Pour tout vecteur $w \in \mathbb{R}^n$,

$$\sum_{i=1}^n (w_i - \bar{w}) = 0.$$

En effet,

$$\sum_{i=1}^n (w_i - \bar{w}) = \sum_{i=1}^n w_i - \sum_{i=1}^n \bar{w} = n\bar{w} - n\bar{w} = 0$$

Solution:

$$(2) \quad \mathbb{E}[\hat{\alpha}] = \alpha \rightarrow \mathbb{E}[\sum a_i Y_i] = \alpha$$

$$\rightarrow \sum_i a_i (\alpha + x_i \beta) = \alpha \quad \text{car} \quad \mathbb{E}[\sum a_i Y_i] = \sum a_i \mathbb{E}[Y_i]$$

$$\rightarrow \alpha \sum_i a_i + \beta \sum_i a_i x_i = \alpha$$

Cette égalité n'est vérifiée que si

$$\sum_i a_i = 1$$

$$\sum_i a_i x_i = 0$$

$$(3) \quad \text{Var}[\hat{\alpha}] = \text{Var}[\sum a_i Y_i] = \sum a_i^2 \text{Var}[Y_i]$$

$$\text{Var}[\hat{\alpha}] = \sigma^2 \sum_i a_i^2$$

$\hat{\alpha}$ est de variance minimale et donc est solution du problème de minimisation

$$\min \text{Var}[\hat{\alpha}]$$

s.c.

$$\sum a_i = 1,$$

$$\sum a_i x_i = 0$$



$$\hat{\alpha} = \underset{\text{s.c.}}{\text{argmin}} \sum_i a_i^2$$

$$\sum a_i = 1,$$

$$\sum a_i x_i = 0$$

La résolution de ce problème d'optimisation par la méthode du Lagrangien (KKI) est fastidieuse. Nous proposons ci-dessous une autre méthode de résolution.

$$\sum_{i=1}^n a_i = 1 \Rightarrow \exists k, \{b_i, i=1, \dots, n\} \text{ constantes tels que } a_i = \frac{1}{n} + k(b_i - \bar{b})$$

(On vérifie aisément que $\sum_{i=1}^n a_i = \sum_{i=1}^n \left(\frac{1}{n} + k(b_i - \bar{b}) \right) = 1$)

* Cherchons de tels k et $\{b_i, i=1, \dots, n\}$

$$\sum_i a_i x_i = 0 \rightarrow \sum_{i=1}^n \left(\frac{1}{n} + k(b_i - \bar{b}) \right) x_i = 0$$

$$\rightarrow \frac{1}{n} \sum_i x_i + k \sum_i (b_i - \bar{b}) x_i = 0$$

$$\rightarrow \frac{1}{n} \sum_i x_i + k \sum_i (b_i - \bar{b})(x_i - \bar{x}) = 0$$

$$\left(\sum_{i=1}^n (b_i - \bar{b})(x_i - \bar{x}) = \sum_{i=1}^n (b_i - \bar{b}) x_i \right)$$

$$\rightarrow \bar{x} + k \sum_i (b_i - \bar{b})(x_i - \bar{x}) = 0$$

d'où

$$k = - \frac{\bar{x}}{\sum_{i=1}^n (b_i - \bar{b})(x_i - \bar{x})}$$

$$a_i = \frac{1}{n} + k(b_i - \bar{b}) \rightarrow a_i = \frac{1}{n} - \frac{\bar{x}(b_i - \bar{b})}{\sum_i (b_i - \bar{b})(x_i - \bar{x})}$$

d) on

$$\begin{aligned} \sum_{i=1}^n a_i^2 &= \sum_i \left\{ \frac{1}{n} - \frac{\bar{x}(b_i - \bar{b})}{\sum_i (b_i - \bar{b})(x_i - \bar{x})} \right\}^2 \\ &= \sum_i \left\{ \frac{1}{n^2} + \frac{\bar{x}^2 (b_i - \bar{b})^2}{\left[\sum_i (b_i - \bar{b})(x_i - \bar{x}) \right]^2} - \frac{2}{n} \frac{\bar{x}(b_i - \bar{b})}{\sum_i (b_i - \bar{b})(x_i - \bar{x})} \right\} \\ &= \sum_i \frac{1}{n^2} + \frac{\bar{x}^2 (b_i - \bar{b})^2}{\left[\sum_i (b_i - \bar{b})(x_i - \bar{x}) \right]^2} - \frac{2}{n} \frac{\bar{x} \sum_i (b_i - \bar{b})}{\sum_i (b_i - \bar{b})(x_i - \bar{x})} \\ &= \frac{1}{n} + \bar{x}^2 \frac{\sum_{i=1}^n (b_i - \bar{b})^2}{\left[\sum_{i=1}^n (b_i - \bar{b})(x_i - \bar{x}) \right]^2} \end{aligned}$$

Minimiser $\sum a_i^2$ revient donc à minimiser

$$\frac{\sum_{i=1}^n (b_i - \bar{b})^2}{\left[\sum_{i=1}^n (b_i - \bar{b})(x_i - \bar{x}) \right]^2}$$

De l'inégalité de Cauchy-Swarz, on sait que

$$\sum_i \left[(b_i - \bar{b})(x_i - \bar{x}) \right]^2 \leq \sum_i (b_i - \bar{b})^2 \sum_i (x_i - \bar{x})^2$$

$$\frac{\sum_i (b_i - \bar{b})^2}{\left[\sum_i (b_i - \bar{b})(x_i - \bar{x}) \right]^2} \geq \frac{\sum_i (b_i - \bar{b})^2}{\sum_i (b_i - \bar{b})^2 \sum_i (x_i - \bar{x})^2}$$

Il en suit que

$$\sum_i a_i^2 \geq \frac{\bar{x}^2}{\sum_i (x_i - \bar{x})^2} = A$$

Le minimum A est atteint à $b_i = x_i$

En effet, remplacer b_i par x_i dans $\sum a_i^2$ et utiliser On a alors

$$\begin{aligned} \frac{\sum (b_i - \bar{b})^2}{\left[\sum (b_i - \bar{b})(x_i - \bar{x}) \right]^2} &= \frac{\sum (x_i - \bar{x})^2}{\left[\sum (x_i - \bar{x})(x_i - \bar{x}) \right]^2} \\ &= \frac{\sum (x_i - \bar{x})^2}{\left(\sum_i (x_i - \bar{x})^2 \right)^2} \\ &= \frac{1}{\sum_i (x_i - \bar{x})^2} \end{aligned}$$

On a donc

$$\begin{cases} b_i = x_i \\ b_a = - \frac{\bar{x}}{\sum_i (b_i - \bar{b})(x_i - \bar{x})} \end{cases}$$

Remplaçons $b_i = x_i$ et obtenons la valeur minimale ~~cas~~, c'est $\hat{\alpha}$ - dire

$$a_i = \frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

et d'où

$$\hat{\alpha} = \sum_i a_i Y_i$$

$$= \sum_i \left(\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_i (x_i - \bar{x})^2} \right) Y_i$$

$$= \frac{1}{n} \sum_i Y_i - \sum_i \frac{(x_i - \bar{x}) Y_i}{\sum_i (x_i - \bar{x})^2}$$

$$= \bar{Y} - \hat{\beta} \bar{x}, \text{ car } \left(\begin{aligned} \hat{\beta} &= \frac{\sum_i (x_i - \bar{x}) Y_i}{\sum_i (x_i - \bar{x})^2} \\ &= \frac{\sum_i (x_i - \bar{x}) (Y_i - \bar{Y})}{\sum_i (x_i - \bar{x})^2} \end{aligned} \right)$$

Conclusion :

$\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{x}$ est l'estimateur des moindres carrés.

Exercice 2

Observations: $(x_i, Y_i)_{i=1, \dots, n}$

Modèle: $Y_i = \alpha + x_i \beta + \varepsilon_i$

x_1, \dots, x_n fixés, constants

$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, les ε_i i.i.d.

Modèle reparamétrisé:

$$Y_i^* = \alpha^* + (x_i - \bar{x}) \beta^* + \varepsilon_i$$

On veut montrer que

- (i) $\hat{\beta} = \hat{\beta}^*$
- (ii) $\hat{\alpha} \neq \hat{\alpha}^*$, $\hat{\alpha} = \bar{Y}$, distribution de $\hat{\alpha}^*$
- (iii) $\hat{\alpha}^*$ et $\hat{\beta}^*$ sont non corrélés et de ce fait indépendants sous la normalité.

Solution:

(i) Posons $z_i = x_i - \bar{x}$ pour tout $i = 1, \dots, n$

Alors $\bar{z} = \frac{1}{n} \sum_i z_i = \frac{1}{n} \sum_i (x_i - \bar{x}) = 0$

et on a:

$$\begin{aligned} \hat{\beta} &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\sum z_i (y_i - \bar{y})}{\sum z_i^2} \\ &= \frac{\sum (z_i - \bar{z})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \hat{\beta}^* \quad (\text{car } \bar{z} = 0) \end{aligned}$$

$$(ii) \quad \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} = \bar{y} - \hat{\beta}^* \bar{x} \quad (\text{car } \hat{\beta} = \hat{\beta}^*)$$

$$\hat{\alpha}^* = \bar{y} - \hat{\beta}^* \bar{z} = \bar{y} \quad (\text{car } \bar{z} = 0)$$

On a clairement :

$$\hat{\alpha} \neq \hat{\alpha}^* \quad \text{puisque } \hat{\beta}^* \neq 0$$

* On vient de montrer que

$$\hat{\alpha}^* = \bar{y} \quad \text{et} \quad \hat{\alpha} \neq \hat{\alpha}^*$$

* Distribution de $\hat{\alpha}^*$

$$\hat{\alpha} = \bar{y} - \hat{\beta}^* \bar{x} = \hat{\alpha}^* - \hat{\beta}^* \bar{x} \quad (\text{car } \hat{\alpha}^* = \bar{y})$$

$$\text{d'où} \quad \hat{\alpha}^* = \hat{\alpha} + \hat{\beta}^* \bar{x}$$

$$E[\hat{\alpha}^*] = E[\hat{\alpha} + \hat{\beta}^* \bar{x}]$$

$$= \alpha + \beta \bar{x}$$

$$\text{Var}[\hat{\alpha}^*] = \text{Var}[\bar{y}] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(y_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

Donc

$$\hat{\alpha}^* \sim \mathcal{N}(\alpha + \beta \bar{x}, \sigma^2/n)$$

(iii) $\hat{\alpha}^*$ est linéaire en $\hat{\alpha}$
 $\text{Cov}(\hat{\alpha}^*, \hat{\beta}^*) = \text{Cov}(\hat{\alpha}^*, \hat{\beta}) \quad (\text{car } \hat{\beta}^* = \hat{\beta})$
 et $\hat{\alpha}^*$ est linéaire en $\hat{\beta}$

Δ'_{ou}

$$\text{Cov}(\hat{\alpha}^*, \hat{\beta}^*) = \text{Cov}(\hat{\alpha} + \hat{\beta} \bar{x}, \hat{\beta})$$

$$= \text{Cov}(\hat{\alpha}, \hat{\beta}) + \bar{x} \text{Cov}(\hat{\beta}, \hat{\beta})$$

$$= \text{Cov}(\hat{\alpha}, \hat{\beta})$$

$$= -\sigma^2 \sum_i \frac{1}{n} \left(\frac{z_i}{\sum_i z_i^2} \right)$$

$$= 0 \quad (\text{as } \sum_i z_i = 0)$$

Question 3:

$$Y_i = x_i^2 \theta + \varepsilon_i, \quad x_1, \dots, x_n \text{ fixés, constants}$$

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2), \text{ i.i.d. pour tout } i$$

(i) Estimateur des moindres carrés de θ , $\hat{\theta}$.

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^n \varepsilon_i^2$$

Rappel: Comment résoudre le problème de minimisation

$$\min_x f(x) \quad ?$$

→ Résoudre en x , $f'(x) = 0$.

La solution de cette équation, notons la \hat{x} , pour être un minimum doit vérifier:

$$\rightarrow f''(\hat{x}) \geq 0.$$

Notons

$$f(\theta) = \sum_i \varepsilon_i^2 = \sum_i (Y_i - x_i^2 \theta)^2$$

$$f'(\theta) = -2 \sum_i (Y_i - x_i^2 \theta) x_i^2$$

$$f'(\theta) = 0 \Rightarrow \sum_i (Y_i - x_i^2 \theta) x_i^2 = 0$$

$$\Rightarrow \sum_i x_i^2 Y_i - \theta \sum_i x_i^4 = 0$$

$$\hat{\theta}_{LS} = \frac{\sum_{i=1}^n x_i^2 y_i}{\sum_{i=1}^n x_i^4}$$

L.S. \equiv Least Square

(i) Estimateur des moindres carrés $\hat{\theta}_{MLE}$ de θ .

Vraisemblance:

$$L(\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y_i - \theta x_i^2)^2}{2\sigma^2} \right\}$$

Log-vraisemblance

$$\log(L(\theta)) \equiv \ell(\theta) = -\log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_i (y_i - \theta x_i^2)^2$$

$$\ell'(\theta) = -\frac{2}{2\sigma^2} \sum_i (y_i - \theta x_i^2) x_i^2$$

$$\ell'(\theta) = 0 \Rightarrow \sum_i (y_i - \theta x_i^2) x_i^2 = 0$$

$$\Rightarrow \left\{ \hat{\theta}_{MLE} = \frac{\sum_{i=1}^n x_i^2 y_i}{\sum_{i=1}^n x_i^4} \right\}$$

(ii) Meilleur estimateur sans biais de θ

$$\ell''(\theta) = -\frac{1}{\sigma^2} \sum_i x_i^4$$

La borne de Brainer-Rao est :

$$\begin{aligned} \text{BCR} &= - E \left[\frac{d^2}{d\theta^2} \ell(\theta) \right] \\ &= + \frac{1}{\sigma^2} \sum_{i=1}^n x_i^4 \end{aligned}$$

Proposition:

$$\left(\text{Var}[\hat{\theta}] = \text{BCR} \right) \Rightarrow \left(\hat{\theta} \text{ est le meilleur estimateur de } \theta \right)$$

• On vérifie aisément que

$$E[\hat{\theta}] = \theta \quad \left(\hat{\theta} = \hat{\theta}_{LS} = \hat{\theta}_{MLE} \right)$$

$$\bullet \text{Var}[\hat{\theta}] = \text{Var} \left[\frac{\sum_{i=1}^n y_i x_i^2}{\sum_{i=1}^n x_i^4} \right]$$

$$= \frac{\sum_{i=1}^n x_i^4 \text{Var}[y_i]}{\left(\sum_{i=1}^n x_i^4 \right)^2}$$

$$= \sigma^2 \frac{\sum_{i=1}^n x_i^4}{\left(\sum_{i=1}^n x_i^4 \right)^2}$$

$$= \sigma^2 / \sum_{i=1}^n x_i^4$$

$$= \text{BCR}$$

Donc

$\hat{\theta}$ est le meilleur estimateur sans biais de θ .