

# Modèles Linéaires Appliqués / Régression

## Régression de Poisson : Inférence

Arthur Charpentier

UQAM

Hiver 2020 - COVID-19 # 8



## Régression de Poisson

Données homogènes  $\{y_1, \dots, y_n\}$  de loi de Poisson,  $Y_i \sim \mathcal{P}(\lambda)$

$$\mathbb{P}(Y = y) = e^{-\lambda} \frac{\lambda^y}{y!}, \forall y \in \mathbb{N}.$$

Données hétérogènes  $\{(y_1, \mathbf{x}_1), \dots, (y_n, \mathbf{x}_n)\}$  de loi de Poisson

$$Y_i \sim \mathcal{P}(\lambda_i) \text{ avec } \lambda_i = \exp[\mathbf{x}_i^\top \boldsymbol{\beta}].$$

Dans ce modèle,  $\mathbb{E}(Y_i | \mathbf{x}_i) = \text{Var}(Y_i | \mathbf{x}_i) = \lambda_i = \exp[\mathbf{x}_i^\top \boldsymbol{\beta}]$ .

Modèle dit **log-linéaire**.

**Remarque:** on posera parfois  $\theta_i = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$  et  $\mu_i = \lambda_i = \exp[\eta_i]$ .

## Régression de Poisson

La log-vraisemblance est ici

$$\log \mathcal{L}(\beta; \mathbf{y}) = \sum_{i=1}^n [y_i \log(\lambda_i) - \lambda_i - \log(y_i!)]$$

i.e.

$$\log \mathcal{L}(\beta; \mathbf{y}) = \sum_{i=1}^n y_i \cdot [\mathbf{x}_i^\top \beta] - \exp[\mathbf{x}_i^\top \beta] - \log(y_i!)$$

Le gradient est ici

$$\nabla \log \mathcal{L}(\beta; \mathbf{y}) = \frac{\partial \log \mathcal{L}(\beta; \mathbf{y})}{\partial \beta} = \sum_{i=1}^n \mathbf{x}_i^\top (y_i - \exp[\mathbf{x}_i^\top \beta])$$

alors que la matrice Hessienne s'écrit

$$H(\beta) = \frac{\partial^2 \log \mathcal{L}(\beta; \mathbf{y})}{\partial \beta \partial \beta^\top} = - \sum_{i=1}^n \exp[\mathbf{x}_i^\top \beta] \mathbf{x}_i \mathbf{x}_i^\top$$

## Régression de Poisson

La condition du premier ordre est ici

$$\mathbf{X}^\top [\mathbf{y} - \exp(\mathbf{X}\hat{\boldsymbol{\beta}})] = \mathbf{0}, \text{ i.e. } \sum_{i=1}^n \mathbf{x}_i^\top [\mathbf{y} - \exp(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})] = \mathbf{0}$$

ce qui signifie  $\mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \hat{\boldsymbol{\lambda}}$  où  $\hat{\boldsymbol{\lambda}} = \exp(\mathbf{X}\hat{\boldsymbol{\beta}})$ .

La matrice Hessienne est  $H(\boldsymbol{\beta}) = -\mathbf{X}^\top \boldsymbol{\Omega} \mathbf{X}$ ,  $\boldsymbol{\Omega} = -\text{diag}(\exp(\mathbf{X}\hat{\boldsymbol{\beta}}))$

Cf slides #2, en posant  $\boldsymbol{\Omega} = \text{diag}(\mathbf{p}(1 - \mathbf{p}))$ ,

$$\nabla \log \mathcal{L}(\boldsymbol{\beta}) = \frac{\partial \log \mathcal{L}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \mathbf{X}^\top (\mathbf{y} - \mathbf{p}) = \mathbf{0} \quad (\text{avec } \mathbf{p} = \mathbf{p}(\boldsymbol{\beta}))$$

$$H(\boldsymbol{\beta}) = \frac{\partial^2 \log \mathcal{L}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} = -\mathbf{X}^\top \boldsymbol{\Omega} \mathbf{X} \quad (\text{avec } \boldsymbol{\Omega} = \boldsymbol{\Omega}(\boldsymbol{\beta}))$$

## Régression de Poisson

Parfois, les données ne sont pas observées pendant la même durée

Données hétérogènes  $\{(y_1, \mathbf{x}_1, e_1), \dots, (y_n, \mathbf{x}_n, e_n)\}$  de loi de Poisson (cf #7 processus de Poisson)

$$Y_i \sim \mathcal{P}(e_i \lambda_i) \text{ avec } \tilde{\lambda}_i = e_i \lambda_i = \exp[\mathbf{x}_i^\top \boldsymbol{\beta} + \log(e_i)].$$

$\log(e_i)$  est appelée **variable offset**.

Parfois les données sont regroupées (cf #9 régression binomiale  $\mathcal{B}(n, p)$ ) et on suppose les groupes homogènes

$$Y_i = \sum_{j=1}^{e_i} Y_{i,j} \text{ avec } Y_{i,j} \sim \mathcal{P}(\lambda_i), \text{ i.i.d., i.e. } Y_i \sim \mathcal{P}(e_i \lambda_i).$$

## Modèles Log-Linéaires

Ici  $Y_i \sim \mathcal{P}(\exp[\mathbf{x}_i^\top \beta])$ .

On pourra considérer (#12)  $Y_i \sim \mathcal{N}(\exp[\mathbf{x}_i^\top \beta], \sigma^2)$ , mais

$$\underbrace{Y_i \sim \mathcal{N}(\exp[\mathbf{x}_i^\top \beta], \sigma^2)}_{\text{modèle GLM sur } y_i} \neq \underbrace{\log Y_i \sim \mathcal{N}(\mathbf{x}_i^\top \beta, \sigma^2)}_{\text{modèle LM sur } \log y_i}$$

Dans le premier cas,  $\mathbb{E}(Y_i) = \exp[\mathbf{x}_i^\top \beta]$

Dans le second cas,  $\mathbb{E}(Y_i) = \exp \left[ \mathbf{x}_i^\top \beta + \frac{\sigma^2}{2} \right]$

Cf loi lognormale, si  $Y \sim \mathcal{LN}(\mu, \sigma^2)$ ,  $\mathbb{E}(Y) = \exp \left[ \mu + \frac{\sigma^2}{2} \right]$

Cf inégalité de Jensen,  $\mathbb{E}(\log X) \leq \log \mathbb{E}(X)$  car  $\log$  concave.

## Modèles Log-Linéaires

Cas de données  $N_{i,j}$  en 'triangle'...

```
1 > library(boot)
2 > data(aids)
3 > head(aids)
4   year quarter delay dud time y
5 1 1983         3     0   0   1 2
6 2 1983         3     2   0   1 6
7 3 1983         3     5   0   1 0
```

Ici  $\text{year:quarter} = \text{date } (i)$  et  $\text{delay} = \text{développement } (j)$

```
33 [33,]    53   175    35    17    13    11     2
34 [34,]    63   135    24    23    12     1    NA
35 [35,]    71   161    48    25     5    NA    NA
36 [36,]    95   178    39     6    NA    NA    NA
37 [37,]    76   181    16    NA    NA    NA    NA
38 [38,]    67    66    NA    NA    NA    NA    NA
```

→ utiliser un facteur ligne  $\mathbf{L} = (L_1, \dots, L_I)$   
et un facteur colonne  $\mathbf{C} = (C_1, \dots, C_J)$

## Modèles Log-Linéaires

Ici  $N_{i,j} \sim \mathcal{P}(L_i \cdot C_j)$  ou  $N_{i,j} \sim \mathcal{P}(\exp(\ell_i + \gamma_j))$

```
1 > Aids = aids
2 > Aids$y[Aids$dud==1] = NA
3 > reg = glm(y~as.factor(delay)+as.factor(time),data=
  Aids,family=poisson)
```

On peut ensuite prévoir,  $\hat{\lambda}_{i,j} = \exp(\hat{\ell}_i + \hat{\gamma}_j)$

```
4 > p = predict(reg,newdata=Aids,type="response")
5 > matrix(p,length(unique(Aids$time)),byrow = TRUE)
6 [33,] 53.8 150.9 43.3 26.5 16.0 13.5 10.1 7.7
7 [34,] 47.6 133.5 38.3 23.4 14.2 11.9 8.9 6.8
8 [35,] 59.8 167.7 48.1 29.4 17.8 15.0 11.2 8.6
9 [36,] 67.7 189.9 54.5 33.3 20.2 16.9 12.7 9.7
10 [37,] 67.5 189.5 54.4 33.2 20.1 16.9 12.7 9.7
11 [38,] 67.0 188.0 53.9 33.0 19.9 16.8 12.6 9.6
```







