# Modèles Linéaires Appliqués / Régression **GLM & Tests**

Arthur Charpentier

**UQAM** 

Hiver 2020 - COVID-19 # 18



### Tests & Intervalles de Confiance

La déviance était définie par

$$D(\mathbf{y}, \widehat{\boldsymbol{\mu}}) = 2\varphi \left[ \log \mathcal{L}(\mathbf{y}) - \log \mathcal{L}(\widehat{\boldsymbol{\mu}}) \right]$$

$$D^{\star}(\mathbf{y}, \widehat{\boldsymbol{\mu}}) = 2 \left[ \log \mathcal{L}(\mathbf{y}) - \log \mathcal{L}(\widehat{\boldsymbol{\mu}}) \right] = \frac{D}{\varphi}$$

Si on veut tester  $H_0: \beta_I = \mathbf{0}$  pour un sous ensemble de variables,  $I \subset \{1, 2, \dots, k\}$ , on fait un test de rapport de vraisemblance

$$LRT = D^{\star}(\widehat{\boldsymbol{\mu}}, \widehat{\boldsymbol{\mu}}_I) = D^{\star}(\boldsymbol{y}, \widehat{\boldsymbol{\mu}}_I) - D^{\star}(\boldsymbol{y}, \widehat{\boldsymbol{\mu}})$$

Sous  $H_0$ ,  $LRT \xrightarrow{\mathcal{L}} \chi^2(k - \dim(I))$ 

#### On a vu que

### Proposition sous les hypothèses mentionnées auparavant

- l'estimateur du maximum de vraisemblance  $\widehat{\boldsymbol{\beta}}$  existe et est unique,
- $\widehat{\beta} \stackrel{p.s.}{\rightarrow} \beta$  (fortement consistant)
- lorsque  $n \to \infty$ .  $\widehat{\beta} \beta \stackrel{\mathcal{L}}{\to} \mathcal{N}(\mathbf{0}, \varphi \mathbf{\Sigma})$

où 
$$\boldsymbol{\Sigma} = (\boldsymbol{X}^{\top} \boldsymbol{W} \boldsymbol{X})^{-1}$$
 et  $\boldsymbol{W} = \operatorname{diag}((V(\mu_i)g'(\mu_i)^2)^{-1}).$ 

### Proposition sous les hypothèses mentionnées auparavant

- lorsque  $n \to \infty$ ,  $\widehat{\eta} \eta \stackrel{\mathcal{L}}{\to} \mathcal{N}(\mathbf{0}, \varphi \mathbf{X} \mathbf{\Sigma} \mathbf{X}^{\top})$
- Iorsque  $n \to \infty$ .  $\hat{\boldsymbol{\mu}} \boldsymbol{\mu} \stackrel{\mathcal{L}}{\to} \mathcal{N}(\boldsymbol{0}, \varphi \boldsymbol{\Delta}^{-2} \boldsymbol{X} \boldsymbol{\Sigma} \boldsymbol{X}^{\top})$

• lorsque  $n \to \infty$ ,  $\widehat{\beta} - \beta \xrightarrow{\mathcal{L}} \mathcal{N}(\mathbf{0}, \omega \Sigma)$ 

```
1 > reg = glm(Survived~Sex+Pclass+Age,family="binomial")
2 > confint(reg)
                   2.5 % 97.5 %
3
 (Intercept) 3.01450041 4.58890189
5 Sexmale
          -2.93866348 -2.12456642
6 Pclass2 -1.86335813 -0.77181573
7 Pclass3 -3.14672951 -2.04176314
8 Age
             -0.05229015 -0.02223298
```

• Iorsque  $n \to \infty$ ,  $\widehat{\mu} - \mu \stackrel{\mathcal{L}}{\to} \mathcal{N}(\mathbf{0}, \varphi \mathbf{\Delta}^{-2} \mathbf{X} \mathbf{\Sigma} \mathbf{X}^{\top})$ 

```
> predict(reg,newdata=newbase,se.fit = TRUE,type="
     response")
2 $fit
 0.9588402 0.1124358
5 $se.fit
6
7 0.01217853 0.01834374
```

En réalité, on utilise ici la vraisemblance profilée

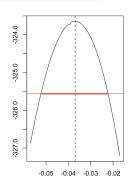
$$\beta = (\beta_1, \dots, \beta_{k-1}, \beta_k)$$
. Pour  $\beta_k$ , on définit

$$\log \mathcal{L}_p(\beta_k) = \log \mathcal{L}((\beta_{-k}^*, \beta_k))$$

où 
$$\beta_{-k}^* = \operatorname{argmax} \{ \log \mathcal{L}((\beta_{-k}, \beta_k)) \}$$
  
L'intervalle de confiance est en :

$$\max\{\log \mathcal{L}_p(\beta_k)\} - \frac{1}{2}q_{\chi^2}(.95)$$

cf test du rapport de vraisemblance



Soit **R** une matrice  $q \times p$  (avec  $q \leq p$ ), alors

$$\frac{1}{\varphi}(\boldsymbol{R}(\widehat{\boldsymbol{\beta}}-\boldsymbol{\beta}))^{\top} \Big(\boldsymbol{R}(\boldsymbol{X}^{\top}\boldsymbol{W}\boldsymbol{X})^{-1}\boldsymbol{R}^{\top}\Big)^{-1}(\boldsymbol{R}(\widehat{\boldsymbol{\beta}}-\boldsymbol{\beta})) \overset{\mathcal{L}}{\rightarrow} \chi^{2}(\boldsymbol{n}-\boldsymbol{p})$$

Si on veut tester  $H_0$ :  $\mathbf{R}\beta = \mathbf{r}_0$ , contre  $H_1$ :  $\mathbf{R}\beta \neq \mathbf{r}_0$ , on utilise

$$Q = \frac{1}{\varphi} (\boldsymbol{R} \widehat{\boldsymbol{\beta}} - \boldsymbol{r}_0)^\top \Big( \boldsymbol{R} (\boldsymbol{X}^\top \boldsymbol{W} \boldsymbol{X})^{-1} \boldsymbol{R}^\top \Big)^{-1} (\boldsymbol{R} \widehat{\boldsymbol{\beta}} - \boldsymbol{r}_0)$$

et sous  $H_0$ ,  $Q \xrightarrow{\mathcal{L}} \chi^2(n-p)$ 



#### Vraisemblance Profilée

```
> p0 = rep(0,4)
2 > profL = function(b){
    Lp = function(p){
3
      eta = X%*%c(p,b)
4
      mu = \exp(eta)/(1+\exp(eta))
5
      -sum(dbinom(reg$y, size = 1, prob=mu,
6
     log=TRUE))}
    -optim(par=p0,fn=Lp)$value }
 > m=profL(coefficients(reg)[5])
 > minf=m-qchisq(.95,df=1)/2
 > abline(h=minf,col="red")
11 > (b1=uniroot(function(z) Vectorize(
     profL)(z) - minf, c(-.06, -.04)) root)
 [1] -0.05227511
13 > (b2=uniroot(function(z) Vectorize(
     profL)(z)-minf,c(-.04,-.02))$root)
14 [1] -0.02225003
```

