

Modèles Linéaires Appliqués / Régression

Famille Exponentielle & Régression

Arthur Charpentier

UQAM

Hiver 2020 - COVID-19 # 13



Régression GLM

$$f(y_i|\theta_i, \varphi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a(\varphi)} + c(y_i, \varphi) \right\}$$

La log-vraisemblance est alors

$$\log \mathcal{L}(\boldsymbol{\theta}, \varphi | \mathbf{y}) = \frac{\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i)}{a(\varphi)} + \sum_{i=1}^n c(y_i, \varphi).$$

Paramètre naturel pour y_i : θ_i

Prédiction pour y_i : $\mu_i = \mathbb{E}(Y_i) = b'(\theta_i)$

Score associé à y_i : $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$

Fonction de lien : g telle que $\eta_i = g(\mu_i) = g(b'(\theta_i))$
(g doit être bijective, et croissante...)

Fonctions Liens : Canonique

Cas particulier : lien canonique $g = b'^{-1}$ i.e. $\eta_i = \theta_i$

$$\mu(\mathbf{x}) = b'(\mathbf{x}^\top \boldsymbol{\beta})$$

Exemple Pour la loi normale, $\mu(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta}$ (identité)

Exemple Pour la loi de Poisson, $\mu(\mathbf{x}) = \exp(\mathbf{x}^\top \boldsymbol{\beta})$ (logarithmique)

Exemple Pour la loi de Bernoulli, $\mu(\mathbf{x}) = \frac{\exp(\mathbf{x}^\top \boldsymbol{\beta})}{1 + \exp(\mathbf{x}^\top \boldsymbol{\beta})}$ (logit)

Exemple Pour la loi Tweedie $V(\mu) = \mu^\gamma$, $\mathbf{x}^\top \boldsymbol{\beta} = \frac{\mu(\mathbf{x})^{1-\gamma}}{1-\gamma}$ (power)

Fonctions Liens : Identité

$$\mu(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\beta}$$

Soit $\mathbf{x}_j = (x_1, \dots, x_j, \dots, x_k)$ et $\mathbf{x}_{j+1} = (x_1, \dots, x_j + 1, \dots, x_k)$

$$\beta_j = \mu(\mathbf{x}_{j+1}) - \mu(\mathbf{x}_j)$$

ou

$$\mu(\mathbf{x}_{j+1}) = \mu(\mathbf{x}_j) + \beta_j$$

Si x_j est une variable indicatrice

$$\beta_j = \left(\frac{1}{n_1} \sum_{i: x_{j,i}=1} y_i \right) - \left(\frac{1}{n_0} \sum_{i: x_{j,i}=0} y_i \right)$$

Fonctions Liens : Logarithmique

$$\mu(\mathbf{x}) = \exp(\mathbf{x}^\top \boldsymbol{\beta})$$

Soit $\mathbf{x}_j = (x_1, \dots, x_j, \dots, x_k)$ et $\mathbf{x}_{j+1} = (x_1, \dots, x_j + 1, \dots, x_k)$

$$\beta_j = \log \frac{\mu(\mathbf{x}_{j+1})}{\mu(\mathbf{x}_j)}$$

ou

$$\mu(\mathbf{x}_{j+1}) = \mu(\mathbf{x}_j) \cdot e^{\beta_j}$$

Si x_j est une variable indicatrice

$$\beta_j = \log \left(\frac{1}{n_1} \sum_{i: x_{j,i}=1} y_i \right) - \log \left(\frac{1}{n_0} \sum_{i: x_{j,i}=0} y_i \right)$$

Fonctions Liens : Logit & Probit

Gaddum (1933), Bliss (1935), ou Berkson (1944)

$$\mu(\mathbf{x}) = \frac{\exp(\mathbf{x}^\top \beta)}{1 + \exp(\mathbf{x}^\top \beta)}$$

ou

$$\text{cote}(\mathbf{x}) = \frac{\mu(\mathbf{x})}{1 - \mu(\mathbf{x})} = e^{\mathbf{x}^\top \beta}$$

$$\text{cote}(\mathbf{x}_{j+1}) = \text{cote}(\mathbf{x}_j) \cdot e^{\beta_j}$$

i.e. e^{β_j} est un rapport de cote, *odds-ratio*.

Pour le modèle Probit, Bliss(1934), pour 'probability unit'

$$\mu(\mathbf{x}) = \Phi(\mathbf{x}^\top \beta)$$

où Φ est la fonction de répartition de la loi $\mathcal{N}(0, 1)$.

Fonctions Liens : cloglog

Supposons que $N|\mathbf{X} = \mathbf{x} \sim \mathcal{P}(\exp[\mathbf{x}^\top \beta])$, alors

$$\mathbb{P}[N = 0|\mathbf{X} = \mathbf{x}] = \exp(-\exp[\mathbf{x}^\top \beta])$$

$$\mathbb{P}[N > 0|\mathbf{X} = \mathbf{x}] = 1 - \exp(-\exp[\mathbf{x}^\top \beta])$$

Si $Y = \mathbf{1}_{N>0}$,

$$Y \sim \mathcal{B}(p_{\mathbf{x}}) \text{ où } p_{\mathbf{x}} = 1 - \exp(-\exp[\mathbf{x}^\top \beta])$$

correspondant au lien [cloglog](#),

$$\mu(\mathbf{x}) = 1 - \exp(-\exp[\mathbf{x}^\top \beta])$$

Modèles Latents

On suppose que $y_i = \mathbf{1}(\tilde{y}_i > 0)$ où \tilde{y}_i est une variable **non-observée** telle que

$$\tilde{y}_i = \mathbf{x}_i^\top \boldsymbol{\beta} - \varepsilon_i$$

Alors

$$\mu_i = \mathbb{P}[Y_i = 1] = \mathbb{P}[\tilde{Y}_i > s] = \mathbb{P}[\mathbf{x}_i^\top \boldsymbol{\beta} - \varepsilon_i > 0] = F(\mathbf{x}_i^\top \boldsymbol{\beta}) = F(\eta_i)$$

- si $F(x) = \frac{e^x}{1 + e^x}$ - loi logistique : modèle logistique
- si $F(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{t^2}{2}\right) dt$ - loi $\mathcal{N}(0, 1)$: probit
- si loi de Gumbel : modèle cloglog

Fonctions Liens : puissance

Plus généralement, on peut envisager un lien puissance

$$\mathbf{x}^\top \boldsymbol{\beta} = \begin{cases} \mu(\mathbf{x})^\lambda & \text{si } \lambda \neq 0 \\ \log \mu(\mathbf{x}) & \text{si } \lambda = 0 \end{cases}$$

Sous R, la syntaxe est

```
1 > glm(Y~X1+X2,family=poisson(link=power(lambda)))
```

Régression GLM

$$f(y_i|\theta_i, \varphi) = \exp \left\{ \frac{y_i\theta_i - b(\theta_i)}{a(\varphi)} + c(y_i, \varphi) \right\}$$

La log-vraisemblance est alors

$$\log \mathcal{L}(\boldsymbol{\theta}, \varphi | \mathbf{y}) = \frac{\sum_{i=1}^n y_i\theta_i - \sum_{i=1}^n b(\theta_i)}{a(\varphi)} + \sum_{i=1}^n c(y_i, \varphi).$$

On peut remplacer $a(\varphi)$ par φ/w_i , w_i est un poids individuel.

Hypothèses

- g est suffisamment régulière (au moins \mathcal{C}^2)
- φ est supposé connu (pour l'instant)
- $n > p = k + 1$ et \mathbf{X} est de plein rang
(et donc $\mathbf{X}^\top \mathbf{X}$ est définie positive)

Régression GLM

$$\log \mathcal{L}(\boldsymbol{\theta}, \varphi, \mathbf{y}) = \sum_{i=1}^n \underbrace{\left[\frac{y_i \theta_i - b(\theta_i)}{\varphi} + c(y_i, \varphi) \right]}_{\log \mathcal{L}_i}.$$

$$\frac{\partial \log \mathcal{L}_i}{\partial \beta_j} = \frac{\partial \log \mathcal{L}_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_j}$$

$$\frac{\partial \log \mathcal{L}_i}{\partial \theta_i} = \frac{y_i - b'(\theta_i)}{\varphi} = \frac{y_i - \mu_i}{\varphi}$$

$$\frac{\partial \theta_i}{\partial \mu_i} = \left(\frac{\partial \mu_i}{\partial \theta_i} \right)^{-1} = \frac{1}{b''(\theta_i)} = \frac{1}{V(\mu_i)}$$

$$\frac{\partial \eta_i}{\partial \beta_j} = \frac{\partial \mathbf{x}_i^\top \boldsymbol{\beta}}{\partial \beta_j} = x_{i,j}$$

Régression GLM

Les conditions du premier ordre s'écrivent

$$\sum_{i=1}^n \frac{\partial \log \mathcal{L}_i}{\partial \beta_j} = \sum_i \frac{\partial \mu_i}{\partial \eta_i} \times \frac{y_i - \mu_i}{V(\mu_i)} x_{ij} = 0, \forall j$$

Pour simplifier, notons que

$$\frac{\partial \mu_i}{\partial \eta_i} = \left(\frac{\partial \eta_i}{\partial \mu_i} \right)^{-1} = (g'(\mu_i))^{-1}$$

Les conditions du premier ordre s'écrivent

$$\mathbf{X}^\top \mathbf{\Omega} (\mathbf{y} - \boldsymbol{\mu}) = \mathbf{0}$$

$$\mathbf{\Omega} = \text{diag}((V(\mu_i)g'(\mu_i))^{-1})$$

mais on utilisera une autre écriture...

Régression GLM

Les conditions du premier ordre s'écrivent

$$\mathbf{X}^\top \mathbf{W} \mathbf{\Delta} (\mathbf{y} - \boldsymbol{\mu}) = \mathbf{0}$$

$$\mathbf{W} = \text{diag}((V(\mu_i)g'(\mu_i)^2)^{-1}) \text{ et } \mathbf{\Delta} = \text{diag}(g'(\mu_i))$$

Remarque: la matrice d'information de Fisher est $\mathbf{X}^\top \mathbf{W} \mathbf{X}$

Remarque: avec la fonction de lien canonique $\mathbf{X}^\top (\mathbf{y} - \boldsymbol{\mu}) = \mathbf{0}$

Régression GLM

Partir d'une valeur initiale β^0

$$\beta^0 \rightarrow \eta^0 = \mathbf{X}\beta^0 \rightarrow \mu^0 = g^{-1}(\eta^0)$$

$$\text{Poser } \mathbf{z}^j = \eta^j + (\mathbf{y} - \mu^j) \cdot \left. \frac{\partial \eta^j}{\partial \mu} \right|_{\mu=\mu^j}$$

Régresser (WLS) \mathbf{z}^j sur \mathbf{X} avec les poids \mathbf{W}^j (évalués en μ^j)

Récupérer β^{j+1} , et itérer

$$\beta^{j+1} = (\mathbf{X}^\top \mathbf{W}^j \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^j (\mathbf{X}\beta^j + \mathbf{\Delta}^j(\mathbf{y} - \mu^j))$$

$$\beta^{j+1} = \beta^j + (\mathbf{X}^\top \mathbf{W}^j \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^j \mathbf{\Delta}^j(\mathbf{y} - \mu^j)$$

Lorsque $\|\beta^{j+1} - \beta^j\| < \epsilon$, on arrête, et $\hat{\beta} = \beta^{j+1}$.

On pose $\mathbf{\Sigma} = (\mathbf{X}^\top \mathbf{W}^j \mathbf{X})^{-1}$

Régression GLM

Proposition sous les hypothèses mentionnées auparavant

- l'estimateur du maximum de vraisemblance $\hat{\beta}$ existe et est unique,
- $\hat{\beta} \xrightarrow{p.s.} \beta$ (fortement consistant)
- lorsque $n \rightarrow \infty$, $\hat{\beta} - \beta \xrightarrow{\mathcal{L}} \mathcal{N}(\mathbf{0}, \varphi \Sigma)$

où $\Sigma = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1}$ et $\mathbf{W} = \text{diag}((V(\mu_i)g'(\mu_i)^2)^{-1})$.

Proposition sous les hypothèses mentionnées auparavant

- lorsque $n \rightarrow \infty$, $\hat{\eta} - \eta \xrightarrow{\mathcal{L}} \mathcal{N}(\mathbf{0}, \varphi \mathbf{X} \Sigma \mathbf{X}^\top)$
- lorsque $n \rightarrow \infty$, $\hat{\mu} - \mu \xrightarrow{\mathcal{L}} \mathcal{N}(\mathbf{0}, \varphi \Delta^{-2} \mathbf{X} \Sigma \mathbf{X}^\top)$

