

Modèles Linéaires Appliqués / Régression GLM & Sur-dispersion

Arthur Charpentier

UQAM

Hiver 2020 - COVID-19 # 17



Poisson Mélange

L'**équidispersion** est une propriété de la loi de **Poisson**: si

$$Y \sim \mathcal{P}(\lambda), \mathbb{E}(Y) = \text{Var}(Y) = \lambda.$$

Si on suppose maintenant que $Y|\Theta \sim \mathcal{P}(\lambda\Theta)$, où Θ suit une loi Gamma de paramètres identiques α (de telle sorte que $\mathbb{E}(\Theta) = 1$), on obtient la loi **binomiale négative**,

$$\mathbb{P}(Y = k) = \frac{\Gamma(k + \alpha^{-1})}{\Gamma(k + 1)\Gamma(\alpha^{-1})} \left(\frac{1}{1 + \lambda/\alpha}\right)^{\alpha^{-1}} \left(1 - \frac{1}{1 + \lambda/\alpha}\right)^k, \forall k \in \mathbb{N}$$

On peut réécrire cette loi, en posant $r = \alpha^{-1}$ et $p = \frac{1}{1 + \alpha\lambda}$

$$f(y) = \binom{y}{y + r - 1} p^r [1 - p]^y, \forall k \in \mathbb{N}$$

Poisson Mélange

ou encore

$$f(y) = \exp \left[y \log(1 - p) + r \log p + \log \binom{y}{y + r - 1} \right], \forall y \in \mathbb{N}$$

qui est une loi de la famille exponentielle, en posant $\theta = \log[1 - p]$, $b(\theta) = -r \log(p)$ et $a(\varphi) = 1$.

Si on calcule la **moyenne**, on obtient

$$\mathbb{E}(Y) = b'(\theta) = \frac{\partial b}{\partial p} \frac{\partial p}{\partial \theta} = \frac{r(1 - p)}{p} = \lambda,$$

et si on calcule la **variance**

$$\text{Var}(Y) = b''(\theta) = \frac{\partial^2 b}{\partial p^2} \left(\frac{\partial p}{\partial \theta} \right)^2 + \frac{\partial b}{\partial p} \frac{\partial^2 p}{\partial \theta^2} = \frac{r(1 - p)}{p^2}$$

Poisson Mélange

Autrement dit

$$\text{Var}(Y) = \frac{1}{p} \mathbb{E}(Y) = [1 + \alpha \cdot \lambda] \cdot \lambda$$

Pour une régression binomiale négative de type 2 (NB2),

$$\mathbb{E}(Y) = \lambda = \mu \text{ et } \text{Var}(Y) = \lambda + \alpha \lambda^2.$$

Le **lien canonique** est $g(\lambda) = \theta$, i.e. $g(\mu) = \log \left(\frac{\alpha \mu}{1 + \alpha \mu} \right)$

Remarque: si $\alpha = 0$, on a une loi de Poisson; si $\alpha = 1$, on a une loi géométrique.

Poisson Mélange

- Poisson, fonction variance $V(\mu) = \mu$, `ml.pois`
- quasiPoisson, fonction variance $V(\mu) = \varphi\mu$,
- géométrique, fonction variance $V(\mu) = \mu + \mu^2$,
- négative binomiale (NB1), fonction variance $V(\mu) = \mu + \alpha\mu$,
`ml.nb1`
- négative binomiale (NB2), fonction variance $V(\mu) = \mu + \alpha\mu^2$,
`ml.nb2`

Test

on note que la surdispersion correspond à une hétérogénéité résiduelle, c'est à dire un **effet aléatoire**. Par exemple on peut supposer que

$$(Y|\mathbf{X} = \mathbf{X}, \mathbf{Z} = \mathbf{z}) \sim \mathcal{P}(\exp[\mathbf{X}^\top \beta + \mathbf{z}^\top \alpha])$$

de telle sorte que si $u = \mathbf{z}^\top \alpha - \mathbb{E}(\mathbf{Z}^\top \alpha | \mathbf{X} = \mathbf{X})$, alors

$$(Y|\mathbf{X} = \mathbf{x}, \mathbf{Z} = \mathbf{z}) \sim \mathcal{P}(\exp[\mathbf{x}^\top \gamma + u])$$

On a un modèle dit à effets fixes, au sens où

$$(Y|\mathbf{X} = \mathbf{x}) \sim \mathcal{P}(\exp[\mathbf{x}^\top \gamma + U]),$$

où $U = \mathbf{z}^\top \alpha - \mathbb{E}(\mathbf{Z}^\top \alpha | \mathbf{X} = \mathbf{x})$. Par exemple, si on suppose que $U \sim \gamma(\alpha, \alpha)$, i.e. d'espérance 1 et de variance $\sigma^2 = \alpha^{-1}$, alors

$$(Y|U = u) \sim \mathcal{P}(\lambda u) \text{ où } \lambda = \exp[\mathbf{x}^\top \gamma],$$

Test

de telle sorte que $\mathbb{E}(Y|U = u) = \text{Var}(Y|U = u)$. Mais si on regarde la loi nonconditionnelle, $\mathbb{E}(Y) = \lambda$ alors que

$$\text{Var}(Y) = \text{Var}(\mathbb{E}[Y|U]) + \mathbb{E}(\text{Var}(Y|U)) = \lambda + \lambda^2 \sigma^2.$$

On peut alors proposer un test de la forme suivante: on suppose que

$$\text{Var}(Y|\mathbf{X} = \mathbf{x}) = \mathbb{E}(Y|\mathbf{X} = \mathbf{x}) + \tau \cdot \mathbb{E}(Y|\mathbf{X} = \mathbf{x})^2,$$

on on cherche à tester

$$H_0 : \tau = 0 \text{ contre } \tau > 0.$$

Parmi les statistiques de test classique, on pourra considérer

$$T = \frac{\sum_{i=1}^n [(Y_i - \hat{\mu}_i)^2 - Y_i]}{\sqrt{2 \sum_{i=1}^n \hat{\mu}_i^2}}$$

qui suit, sous H_0 , une loi normale centrée réduite.

