

# Modèles Linéaires Appliqués

Arthur Charpentier

Automne 2Q20

OLS #14 (sélection de variables)

## Sélection de variables

- ▶  $\xi$  un sous-ensemble d'indices  $\subseteq \{1, \dots, p\}$  de cardinal  $|\xi|$ .
- ▶  $\mathbf{X}_\xi$  sous-matrice des covariables  $\mathbf{x}_j, j \in \xi$ .
- ▶ Dans le modèle  $\xi$  sélectionnant  $|\xi|$  variables, les paramètres associés sont notés  $\beta_\xi$ .
- ▶  $[\hat{\beta}]_\xi$ : coordonnées  $\xi$  du vecteur  $\hat{\beta}$ ;  $[\hat{\beta}]_\xi \neq \hat{\beta}_\xi$  sauf si  $\mathcal{V}(\mathbf{X}_\xi) \perp \mathcal{V}(\mathbf{X}_{\xi^c})$ .
- ▶ soit une nouvelle observation  $\mathbf{x}'^* = (\mathbf{x}'_\xi^*, \mathbf{x}'_{\xi^c}^*)$ , on note  $\hat{Y}^* = \mathbf{x}'^* \hat{\beta}$  et  $\hat{Y}_\xi^* = \mathbf{x}'_\xi^* \hat{\beta}_\xi$ .
- ▶ si  $n^*$  nouvelles observations:  $\hat{\mathbf{Y}}^* = \mathbf{X}^* \hat{\beta}$  et  $\hat{\mathbf{Y}}_\xi^* = \mathbf{X}_\xi^* \hat{\beta}_\xi$ .

## Sélection de variables

- ▶ supposons disposer de  $p = 3$  covariables et que le vrai modèle soit le modèle linéaire homoscédastique suivant:

$$\mathbf{Y} = \beta_1 \mathbf{x}_1 + \beta_2 \mathbf{x}_2 + \varepsilon = \mathbf{X}_{12} \boldsymbol{\beta}_{12} + \varepsilon, \quad \xi = \{1, 2\}.$$

(pour alléger on supprime les ", " et les {}, ainsi  $\mathbf{X}_{12} = \mathbf{X}_{\{1,2\}}$ ).

- ▶ 7 modèles sont potentiellement envisageables:  
 $\xi = \{1\}, \{2\}, \{3\}, \{1, 2\}, \{1, 3\}, \{2, 3\}, \{1, 2, 3\}$ .
- ▶ choix incorrect = trop peu ou trop de covariables!
- ▶ Examinons simplement ce qui se passe si  $\xi = \{1\}$

$$\hat{\beta}_1 = (\mathbf{X}_1^\top \mathbf{X}_1)^{-1} \mathbf{X}_1^\top \mathbf{Y}, \quad \hat{\mathbf{Y}}_1 = \mathcal{P}_{\mathbf{X}_1} \mathbf{Y}, \quad \hat{\sigma}_1^2 = \|\mathcal{P}_{\mathbf{X}_1^\perp} \mathbf{Y}\|^2 / (n-1).$$

## Sélection de variables

- $\mathbb{E}\mathbf{Y} = \beta_1\mathbf{x}_1 + \beta_2\mathbf{x}_2 = \beta_1\mathbf{X}_1 + \beta_2\mathbf{X}_2$  donc

$$\mathbb{E}\hat{\beta}_1 = \beta_1 + (\mathbf{X}_1^\top \mathbf{X}_1)^{-1} \mathbf{X}_1^\top \mathbf{X}_2 \beta_2$$

$$\mathbb{E}\hat{Y}_1 = \mathbf{X}_1 \beta_1 + \mathcal{P}_{\mathbf{X}_1} \mathbf{X}_2 \beta_2 = \mathbb{E}Y - \mathcal{P}_{\mathbf{X}_1^\perp} \mathbf{X}_2 \beta_2.$$

- et pour l'estimateur de la variance

$$\begin{aligned}\mathbb{E}\hat{\sigma}_1^2 &= \frac{1}{n-1} \mathbb{E} \text{tr}(\mathbf{Y}^\top \mathcal{P}_{\mathbf{X}_1^\perp} \mathbf{Y}) = \frac{1}{n-1} \text{tr}(\mathcal{P}_{\mathbf{X}_1^\perp} \mathbb{E}(\mathbf{Y}\mathbf{Y}^\top)) \\ &= \frac{1}{n-1} \text{tr}(\mathcal{P}_{\mathbf{X}_1^\perp} (\sigma^2 \mathbb{I}_n + \mathbb{E}(\mathbf{Y})\mathbb{E}(\mathbf{Y})^\top)) \\ &= \sigma^2 + \frac{1}{n-1} \beta_{12}^\top \mathbf{X}_{12}^\top \mathcal{P}_{\mathbf{X}_1^\perp} \mathbf{X}_{12} \beta_{12} \\ &= \sigma^2 + \frac{1}{n-1} \beta_2^2 \|\mathcal{P}_{\mathbf{X}_1^\perp} \mathbf{X}_2\|^2.\end{aligned}$$

- $\hat{\beta}_\xi$  et  $\hat{Y}_\xi$  sont en général biaisés.
- $\hat{\sigma}_\xi^2$  est en général positivement biaisé.

# Sélection de variables

modèle	estimations	propriétés
$Y_1 = X_1\beta_1 + \varepsilon$	$\hat{Y}_1 = X_1\hat{\beta}_1$ $\hat{\sigma}_1^2 = \frac{\ P_{X_1^\perp} Y\ ^2}{n-1}$	$B(\hat{Y}_1) = P_{X_1^\perp} X_2\beta_2$ $B(\hat{\sigma}_1^2) = \frac{1}{n-1}\beta_2^2\ P_{X_1^\perp} X_2\ ^2$
$Y = X_2\beta_2 + \varepsilon$	$\hat{Y}_2 = X_2\hat{\beta}_2$ $\hat{\sigma}_2^2 = \frac{\ P_{X_2^\perp} Y\ ^2}{n-1}$	$B(\hat{Y}_2) = P_{X_2^\perp} X_1\beta_1$ $B(\hat{\sigma}_2^2) = \frac{1}{n-1}\beta_1^2\ P_{X_2^\perp} X_1\ ^2$
$Y = X_3\beta_3 + \varepsilon$	$\hat{Y}_3 = X_3\hat{\beta}_3$ $\hat{\sigma}_3^2 = \frac{\ P_{X_3^\perp} Y\ ^2}{n-1}$	$B(\hat{Y}_3) = P_{X_3^\perp} X_{12}\beta_{12}$ $B(\hat{\sigma}_3^2) = \frac{1}{n-1}\beta_{12}'X_{12}'P_{X_{12}^\perp}X_{12}\beta_{12}$
$Y = X_{12}\beta_{12} + \varepsilon$	$\hat{Y}_{12} = X_{12}\hat{\beta}_{12}$ $\hat{\sigma}_{12}^2 = \frac{\ P_{X_{12}^\perp} Y\ ^2}{n-2}$	$B(\hat{Y}_{12}) = 0$ $B(\hat{\sigma}_{12}^2) = 0$
$Y = X_{13}\beta_{13} + \varepsilon$	$\hat{Y}_{13} = X_{13}\hat{\beta}_{13}$ $\hat{\sigma}_{13}^2 = \frac{\ P_{X_{13}^\perp} Y\ ^2}{n-2}$	$B(\hat{Y}_{13}) = P_{X_{13}^\perp} X_{12}\beta_{12}$ $B(\hat{\sigma}_{13}^2) = \frac{1}{n-2}\beta_{12}'X_{12}'P_{X_{13}^\perp}X_{12}\beta_{12}$
$Y = X_{23}\beta_{23} + \varepsilon$	$\hat{Y}_{23} = X_{23}\hat{\beta}_{23}$ $\hat{\sigma}_{23}^2 = \frac{\ P_{X_{23}^\perp} Y\ ^2}{n-2}$	$B(\hat{Y}_{23}) = P_{X_{23}^\perp} X_{12}\beta_{12}$ $B(\hat{\sigma}_{23}^2) = \frac{1}{n-2}\beta_{12}'X_{12}'P_{X_{23}^\perp}X_{12}\beta_{12}$
$Y = X_{123}\beta_{123} + \varepsilon$	$\hat{Y}_{123} = X_{123}\hat{\beta}_{123}$ $\hat{\sigma}_{123}^2 = \frac{\ P_{X_{123}^\perp} Y\ ^2}{n-3}$	$B(\hat{Y}_{123}) = 0$ $B(\hat{\sigma}_{123}^2) = 0$

(via Cornillon & Matzner-Løber (2007))

## Sélection de variables

$$\text{Var}(\hat{\beta}_1) = \sigma^2(\mathbf{X}_1^\top \mathbf{X}_1)^{-1}, \quad \text{Var}(\hat{\beta}_{12}) = \sigma^2 \begin{pmatrix} \mathbf{X}_1^\top \mathbf{X}_1 & \mathbf{X}_1^\top \mathbf{X}_2 \\ \mathbf{X}_2^\top \mathbf{X}_1 & \mathbf{X}_2^\top \mathbf{X}_2 \end{pmatrix}^{-1}$$

$$\text{Var}(\hat{\beta}_{123}) = \sigma^2 \begin{pmatrix} \mathbf{X}_1^\top \mathbf{X}_1 & \mathbf{X}_1^\top \mathbf{X}_2 & \mathbf{X}_1^\top \mathbf{X}_3 \\ & \mathbf{X}_2^\top \mathbf{X}_2 & \mathbf{X}_2^\top \mathbf{X}_3 \\ & \mathbf{X}_3^\top \mathbf{X}_2 & \mathbf{X}_3^\top \mathbf{X}_3 \end{pmatrix}^{-1}.$$

De même

$$\text{Var}(\hat{\mathbf{Y}}_1) = \sigma^2 \mathcal{P}_{\mathbf{X}_1}, \quad \text{Var}(\hat{\mathbf{Y}}_{12}) = \sigma^2 \mathcal{P}_{\mathbf{X}_{12}} = \sigma^2 \mathcal{P}_{\mathbf{X}_1} + \sigma^2 \mathcal{P}_{\mathbf{X}_1^\perp \cap \mathbf{X}_2},$$

$$\text{Var}(\hat{\mathbf{Y}}_{123}) = \sigma^2 \mathcal{P}_{\mathbf{X}_1} + \sigma^2 \mathcal{P}_{\mathbf{X}_1^\perp \cap \mathbf{X}_{23}}.$$

- ▶  $\text{Var}([\hat{\beta}]_\xi) - \text{Var}(\hat{\beta}_\xi)$  est une matrice semi-définie positive.
- ▶  $\text{Var}(\hat{\mathbf{Y}}) \geq \text{Var}(\hat{\mathbf{Y}}_\xi)$ .

## Sélection de variables

$$\text{EQM}(\hat{\theta}) = \text{MSE}(\hat{\theta}) = \mathbb{E}((\hat{\theta} - \theta)^2) = (\mathbb{E}(\hat{\theta}) - \theta)^2 + \text{Var}(\hat{\theta})$$

(quantité pertinente également si  $\hat{\theta}$  est un vecteur, mais on regardera  $\text{tr}(\text{EQM}(\hat{\theta}))$ )



$$\text{tr}(\text{EQM}(\hat{\mathbf{Y}}_{\xi})) = |\xi|\sigma^2 + \|\mathcal{P}_{\mathbf{X}_{\xi}^{\perp}} \mathbf{X}\beta\|^2.$$

- ▶ (si nouvelles données sont indépendantes des observations)

$$\text{tr}(\text{EQMP}(\hat{\mathbf{Y}}_{\xi}^*)) = n^*\sigma^2 + \text{tr}(\text{EQM}(\mathbf{X}_{\xi}^* \hat{\beta}_{\xi}))$$

## Sélection de variables

- Concernant  $\hat{\mathbf{Y}}_\xi$

$$\text{tr}(\text{EQM}(\hat{\mathbf{Y}}_\xi)) = |\xi|\sigma^2 + \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{X}_{12} \boldsymbol{\beta}_{12}\|^2, \quad \xi = 1, 2, 3, 23, 13,$$

$$\text{tr}(\text{EQM}(\hat{\mathbf{Y}}_{12})) = 2\sigma^2 \text{ et } \text{tr}(\text{EQM}(\hat{\mathbf{Y}}_{123})) = 3\sigma^2.$$

(si quantités calculables, on pourrait sélectionner, selon  $\sigma^2$  un modèle qui ne soit pas le bon modèle mais pour lequel l'EQM plus faible)

- Concernant  $\hat{\mathbf{Y}}_\xi^*$

$$\text{tr}(\text{EQMP}(\hat{\mathbf{Y}}_\xi^*)) = (n^* + |\xi|)\sigma^2 + \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{X}_{12}^* \boldsymbol{\beta}_{12}\|^2, \quad \xi = 1, 2, 3, 13, 23,$$

$$\text{tr}(\text{EQMP}(\hat{\mathbf{Y}}_{12}^*)) = (n^* + 2)\sigma^2 \text{ et } \text{tr}(\text{EQMP}(\hat{\mathbf{Y}}_{123}^*)) = (n^* + 3)\sigma^2.$$

- On peut montrer que  $\text{tr}(\text{EQMP}(\hat{\mathbf{Y}}_\xi^*))$  est un très mauvais critère, qui sélectionne le modèle ayant le plus de covariables!



## Sélection de variables

- ▶ si les modèles concurrents sont emboîtés les uns dans les autres, il est possible d'utiliser une procédure de test.
- ▶ notation: modèle  $\xi$  à  $|\xi|$  variables et  $\xi_{+1}$  modèle  $\xi$  auquel on a rajouté une variable.
- ▶ dire que le modèle  $\xi$  est le bon  $\leftrightarrow \mathbb{E}(\mathbf{Y}) \in \mathcal{V}(\mathbf{X}_\xi)$ .
- ▶  $\text{SCR}(\xi)$  somme des carrés des résidus du modèle  $\xi$ ,  
 $= \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{Y}\|^2$ .

On veut tester  $H_0 : \mathbb{E}(\mathbf{Y}) \in \mathcal{V}(\mathbf{X}_\xi)$  contre  $H_1 : \mathbb{E}(\mathbf{Y}) \in \mathcal{V}(\mathbf{X}_{\xi+1})$  au seuil  $\alpha$ . La statistique de test est

$$F = \frac{\text{SCR}(\xi) - \text{SCR}(\xi_{+1})}{\hat{\sigma}_\bullet^2} \text{ où } \hat{\sigma}_a^2 = \frac{\text{SCR}(\xi_{+1})}{n - |\xi| - 1} \text{ ou } \hat{\sigma}_b^2 = \frac{\text{SCR}(2 : p)}{n - p}.$$

Le modèle  $\xi$  est rejeté au profit de  $\xi_{+1}$  si  $f_{\text{obs}} > f_{1-\alpha, 1, n-d_\bullet-1}$  avec  $d_a = |\xi|$  et  $d_b = p$

## Sélection de variables

- ▶  $R^2(\xi) = 1 - \text{SCR}(\xi) / \|\mathbf{Y} - \bar{Y}\|^2$ .
- ▶  $R^2(\xi)$  croît avec  $|\xi|$  (lorsque les modèles sont emboîtés).
- ▶  $\xi_1, \xi_2$ ,  $|\xi_1| = |\xi_2|$ , pertinent de comparer  $R^2(\xi_1)$  à  $R^2(\xi_2)$ .
- ▶ Maximiser  $R_a^2(\xi)$  revient à minimiser  $\text{SCR}(\xi)$  puisque

$$R_a^2(\xi) = 1 - \frac{n-1}{n-|\xi|} (1 - R^2(\xi)) = 1 - \frac{n-1}{\|\mathbf{Y} - \bar{Y}\|^2} \frac{\text{SCR}(\xi)}{n-|\xi|}.$$

Le  $C_p(\xi)$  de Mallows d'un modèle à  $|\xi|$  variables explicatives est

$$C_p(\xi) = \frac{\text{SCR}(\xi)}{\hat{\sigma}^2} - n + 2|\xi|, \quad \text{où } \hat{\sigma}^2 = \text{SCR}(\{2 : p\}) / (n - p)$$

$$\begin{aligned} \mathbb{E}(\text{SCR}(\xi)) &= \mathbb{E}\|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{Y}\|^2 = \mathbb{E}\|\mathcal{P}_{\mathbf{X}_\xi^\perp} (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})\|^2 \\ &= \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{X}\boldsymbol{\beta}\|^2 + \sigma^2 \text{tr}(\mathcal{P}_{\mathbf{X}_\xi^\perp}) = \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{X}\boldsymbol{\beta}\|^2 + (n - |\xi|)\sigma^2. \end{aligned}$$

Rappelons que  $\text{tr}(\text{EQM}(\hat{\mathbf{Y}}_\xi)) = \|\mathcal{P}_{\mathbf{X}_\xi^\perp} \mathbf{X}\boldsymbol{\beta}\|^2 + |\xi|\sigma^2$  implique

$$\mathbb{E}(\hat{\sigma}^2 C_p(\xi)) = \text{tr}(\text{EQM}(\hat{\mathbf{Y}}_\xi)).$$

## Sélection de variables

- Pour que  $\hat{\sigma}^2 C_p$  soit un bon estimateur de l'EQM, il faut que l'estimation des paramètres et le choix des modèles ne dépendent pas des données, ce qui est rarement le cas.
- L'estimateur du  $C_p$  est biaisé: *biais de sélection*.

**Rappel:** sous l'hypothèse de normalité du bruit additif, la log-vraisemblance du modèle à  $\xi$  variables explicatives évaluée à l'EMV vaut

$$\log \mathcal{L}(\xi) = -\frac{n}{2} \log \frac{\text{SCR}(\xi)}{n} - \frac{n}{2} (1 + \log 2\pi).$$

- Maximiser la vraisemblance revient à minimiser  $\text{SCR}(\xi)$ , un terme de pénalisation doit être introduit de la forme

$$-2 \log \mathcal{L}(\xi) + 2|\xi|f(n)$$

où  $f(n)$  est une pénalisation dépendant de  $n$ .

## AIC & BIC

- ▶ Critère d'information d'Akaike (1973),

$$\text{AIC}(\xi) = -2 \log \mathcal{L}(\xi) + 2|\xi| = n \log \frac{\text{SCR}(\xi)}{n} + 2|\xi| + cte.$$

(autrement dit  $f(n) = 1$ ).

- ▶ Bayesain Information Criterion (Schwarz, 1978)

$$\text{BIC}(\xi) = -2 \log \mathcal{L}(\xi) + |\xi| \log n = n \log \frac{\text{SCR}(\xi)}{n} + |\xi| \log n + cte.$$

(autrement dit  $f(n) = .5 \log n$ ).

- ▶ dès que  $n > 7$ ,  $\log(n) > 2$  donc le critère BIC a tendance à sélectionner des modèles plus petits que l'AIC.

## Sélection de variables

- ▶ Par les tests de Fisher, on conservera  $\xi$  si (en notant  $f = f_{.95,1,n-|\xi|-1}$ ) si

$$\frac{\text{SCR}(\xi) - \text{SCR}(\xi_{+1})}{\text{SCR}(\xi_{+1})/(n - |\xi| - 1)} < f \simeq 4.$$

- ▶ Pour le  $R_a^2$

$$R_a^2(\xi) > R_a^2(\xi_{+1}) \iff \frac{\text{SCR}(\xi) - \text{SCR}(\xi_{+1})}{\text{SCR}(\xi_{+1})/(n - |\xi| - 1)} < 1$$

- ▶ Pour le  $C_p$

$$C_p(\xi) < C_p(\xi_{+1}) \iff \frac{\text{SCR}(\xi) - \text{SCR}(\xi_{+1})}{\text{SCR}(2 : p)/(n - p)} < 2$$

- ▶ Pour les critères de vrais. pénalisés: AIC,

$$\text{AIC}(\xi) < \text{AIC}(\xi_{+1}) \iff \frac{\text{SCR}(\xi) - \text{SCR}(\xi_{+1})}{\text{SCR}(\xi_{+1})/(n - |\xi| - 1)} \leq 2f(n) \left(1 - \frac{|\xi| + 1}{n}\right)$$

## Sélection de variables avec R

Première possibilité, tester tous les modèles (exhaustif)

```
1 > library(leaps)
2 > models = regsubsets(Fertility~., data = swiss, nvmax
  = 5)
3 > summary(models)
4 Subset selection object
5 1 subsets of each size up to 5
6 Selection Algorithm: exhaustive
7
8      Agricult  Examinat  Education  Catholic  Infant
9 1 ( 1 ) " "      " "      "*"      " "      " "
10 2 ( 1 ) " "      " "      "*"      "*"      " "
11 3 ( 1 ) " "      " "      "*"      "*"      "*"
12 4 ( 1 ) "*"      " "      "*"      "*"      "*"
13 5 ( 1 ) "*"      "*"      "*"      "*"      "*"
14 > res.sum = summary(models)
15 > Adj.R2 = which.max(res.sum$adjr2),
16 > CP = which.min(res.sum$cp),
17 > BIC = which.min(res.sum$bic)
18 Adj.R2 CP BIC
1      5  4  4
```

## Sélection de variables avec R

Autre possible, les approches hiérarchiques (e.g. *backward*)

```
1 > step(lm(Fertility ~., data = swiss))
2 Start:  AIC=190.69
3 Fertility ~ Agriculture + Examination + Education +
4   Catholic +
5   Infant.Mortality
6
7           Df Sum of Sq    RSS   AIC
8 - Examination      1      53.03 2158.1 189.86
9 <none>                2105.0 190.69
10 - Agriculture      1     307.72 2412.8 195.10
11 - Infant.Mortality  1     408.75 2513.8 197.03
12 - Catholic         1     447.71 2552.8 197.75
13 - Education        1    1162.56 3267.6 209.36
```

(à suivre)

## Sélection de variables avec R

```
1 Step:  AIC=189.86
2 Fertility ~ Agriculture + Education + Catholic +
   Infant.Mortality
3
4           Df Sum of Sq    RSS    AIC
5 <none>                2158.1  189.86
6 - Agriculture          1    264.18 2422.2  193.29
7 - Infant.Mortality     1    409.81 2567.9  196.03
8 - Catholic             1    956.57 3114.6  205.10
9 - Education            1   2249.97 4408.0  221.43
```

Le meilleur modèle selon le AIC est celui avec les 4 dernières variables.



## Sélection de variables avec R

```
1 Step:  AIC=189.86
2 Fertility ~ Agriculture + Education + Catholic +
   Infant.Mortality
3
4           Df Sum of Sq    RSS    AIC
5 <none>                2158.1  189.86
6 - Agriculture          1    264.18 2422.2  193.29
7 - Infant.Mortality     1    409.81 2567.9  196.03
8 - Catholic             1    956.57 3114.6  205.10
9 - Education            1   2249.97 4408.0  221.43
```

Le meilleur modèle selon le AIC est celui avec les 4 dernières variables.

## Sélection de variables avec R

voir aussi

```
1 > model = lm(Fertility ~., data = swiss)
2 > step.model = stepAIC(model, direction = "backward")
3 Start: AIC=190.69
4 Fertility ~ Agriculture + Examination + Education +
5     Catholic +
6     Infant.Mortality
7
8           Df Sum of Sq    RSS    AIC
9 <none>                2105.0  190.69
10 - Agriculture      1    307.72  2412.8  195.10
11 - Infant.Mortality 1    408.75  2513.8  197.03
12 - Catholic         1    447.71  2552.8  197.75
13 - Education         1   1162.56  3267.6  209.36
```

(à suivre)

## Sélection de variables avec R

voir aussi

```
1 Step:  AIC=189.86
2 Fertility ~ Agriculture + Education + Catholic +
   Infant.Mortality
3
4           Df Sum of Sq    RSS    AIC
5 <none>                2158.1  189.86
6 -  Agriculture         1    264.18  2422.2  193.29
7 -  Infant.Mortality     1    409.81  2567.9  196.03
8 -   Catholic           1    956.57  3114.6  205.10
9 -  Education           1   2249.97  4408.0  221.43
```

Là encore, le meilleur modèle selon le AIC est celui avec les 4 dernières variables.

## Sélection de variables avec R

On peut aussi regarder une approche *forward*

```
1 > model0 = lm(Fertility ~ 1, data = swiss)
2 > stepAIC(model0, direction="forward", scope=list(
    lower=model0, upper=model))
3 Start:  AIC=238.35
4 Fertility ~ 1
5
6           Df Sum of Sq    RSS    AIC
7 + Education      1    3162.7 4015.2 213.04
8 + Examination    1    2994.4 4183.6 214.97
9 + Catholic       1    1543.3 5634.7 228.97
10 + Infant.Mortality 1    1245.5 5932.4 231.39
11 + Agriculture    1     894.8 6283.1 234.09
12 <none>              7178.0 238.34
```

(à suivre)

## Sélection de variables avec R

```
1 Step:   AIC=213.04
2 Fertility ~ Education
3
4           Df Sum of Sq    RSS    AIC
5 + Catholic      1      961.07 3054.2 202.18
6 + Infant.Mortality 1      891.25 3124.0 203.25
7 + Examination     1      465.63 3549.6 209.25
8 <none>                4015.2 213.04
9 + Agriculture      1       61.97 3953.3 214.31
10
11 Step:   AIC=202.18
12 Fertility ~ Education + Catholic
13
14           Df Sum of Sq    RSS    AIC
15 + Infant.Mortality 1      631.92 2422.2 193.29
16 + Agriculture      1      486.28 2567.9 196.03
17 <none>                3054.2 202.18
18 + Examination     1        2.46 3051.7 204.15
```

(à suivre)

## Sélection de variables avec R

```
1 Step:  AIC=193.29
2 Fertility ~ Education + Catholic + Infant.Mortality
3
4           Df Sum of Sq    RSS    AIC
5 + Agriculture  1    264.176 2158.1 189.86
6 <none>                2422.2 193.29
7 + Examination  1      9.486 2412.8 195.10
8
9 Step:  AIC=189.86
10 Fertility ~ Education + Catholic + Infant.Mortality +
    Agriculture
11
12           Df Sum of Sq    RSS    AIC
13 <none>                2158.1 189.86
14 + Examination  1    53.027 2105.0 190.69
15
16 Call:
17 lm(formula = Fertility ~ Education + Catholic + Infant
    .Mortality + Agriculture, data = swiss)
```

## Sélection de variables avec R

```
1 > library(leaps)
2 forward =regsubsets(Fertility ~.,data = swiss, method
  = "forward", nbest=1)
3 backward = regsubsets(Fertility ~.,data = swiss,
  method = "backward", nbest=1)
4 stepwise = regsubsets(Fertility ~., data = swiss,
  method = "seqrep", nbest=1)
5 best_subset = regsubsets(Fertility ~.,data = swiss,
  method = "exhaustive", nbest=1)
```


# Sélection de variables avec R

On peut utiliser le  $R^2$  ajusté,  $R_a^2$


$$R_a^2(\xi) = 1 - \frac{n-1}{n-|\xi|}(1 - R^2(\xi))$$

```
1 > plot(forward, scale = "adjr2")
2 > plot(backward, scale = "adjr2")
3 > plot(stepwise, scale = "adjr2")
4 > plot(best_subset,
5     scale = "adjr2")
```


Forward Selection




Backward Selection



Stepwise selection



Best subset selection






# Sélection de variables avec R

On peut utiliser le *BIC*


$$\text{BIC}(\xi) = -2 \log \mathcal{L}(\xi) + |\xi| \log n$$

```
1 > plot(forward, scale = "bic")
2 > plot(backward, scale = "bic")
3 > plot(stepwise, scale = "bic")
4 > plot(best_subset,
5     scale = "bix")
```


Forward Selection




Backward Selection



Stepwise selection



Best subset selection



# Sélection de variables avec R

On peut utiliser le  $C_p$

$$C_p(\xi) = \frac{\text{SCR}(\xi)}{\hat{\sigma}^2} - n + 2|\xi|$$

```
1 > plot(forward, scale = "Cp")
2 > plot(backward, scale = "Cp")
3 > plot(stepwise, scale = "Cp")
4 > plot(best_subset, scale = "Cp")
```

