

# Modèles Linéaires Appliqués

Arthur Charpentier

Automne 2Q20

OLS #15 (moindres carrés généralisés - MCG)

## Régression Linéaire

- Supposons dans ce cours disposer d'un modèle linéaire

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

où  $\mathbf{X}$  est une matrice satisfaisant l'hypothèse  $\mathcal{H}_1$  ( $\mathbf{X}$  est de rang plein).

- On supposera disposer du modèle correct (bon ensemble de covariables et correctement transformées), et que le modèle n'exhibe pas de point aberrant ni de point levier; hypothèses difficilement satisfaites en pratique!
- En revanche, on suppose

$$\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0} \text{ et } \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \boldsymbol{\Omega}$$

où  $\boldsymbol{\Omega}$  est une matrice symétrique définie positive!

- Le modèle est dit hétéroscédastique: quelles sont les conséquences? comment y remédier?

## Données Agrégées

- Supposons qu'un modèle linéaire homoscédastique standard existe entre une variable  $\tilde{Y}$  et un ensemble de variables explicatives pour  $n_1 + \dots + n_k$  individus; supposons justement qu'on n'observe pas le modèle au niveau individuel mais au niveau agrégé pour les  $n_j$  individus.

- On observe:  $Y_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \tilde{Y}_{j:i}$  et le modèle s'écrit toujours:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

- On note que  $\text{Var}(Y_i) = n_i^{-2} \sum_j \text{Var}(\tilde{Y}_j) = \sigma^2/n_i$  et ainsi

$$\text{Var}(\mathbf{Y}) = \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \boldsymbol{\Omega} = \sigma^2 \underbrace{\text{diag}\left(\frac{1}{n_1}, \dots, \frac{1}{n_k}\right)}_{\boldsymbol{\Omega}}$$

## Groupes

- ▶ Partons d'un modèle linéaire homoscédastique  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ , et supposons que les individus soient regroupés en deux groupes de taille  $n_1$  et  $n_2$ ,  $n = n_1 + n_2$  (par exemple discriminés par une variable sexe);
- ▶ Il n'est pas insensé de penser que  $\text{Var}(\varepsilon_i) = \sigma_1^2$  pour  $i = 1, \dots, n_1$  et  $\sigma_2^2$  pour  $i = n_1 + 1, \dots, n_1 + n_2$ .
- ▶ les paramètres  $\sigma_1^2$  et  $\sigma_2^2$  sont inconnus!
- ▶ Pour cet exemple, on aurait

$$\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \underbrace{\text{diag}(\pi_1^2, \dots, \pi_1^2, \pi_2^2, \dots, \pi_2^2)}_{\boldsymbol{\Omega}}$$

avec  $\sigma_j^2 = \sigma^2 \pi_j^2$ ,  $j = 1, 2$ .

## Corrélation Temporelle

- Supposons que le bruit soit homogène en variance. En revanche, on supposera que la série  $Y_1, \dots, Y_n$  soit une série chronologique (acquise au cours du temps). Il paraît sensé alors que

$$\text{Cov}(\varepsilon_i, \varepsilon_j) \neq 0, \quad i \neq j.$$

- L'exemple le plus simple d'une telle série est un modèle AR(1):  $\varepsilon_{t+1} = \rho\varepsilon_t + \eta_t$  où  $|\rho| < 1$  et  $\eta_t$  est un bruit blanc gaussien de variance  $\sigma^2$ .
- On montre que  $\text{Cov}(\varepsilon_t, \varepsilon_{t+k}) = \sigma^2 \frac{\rho^k}{1-\rho^2}$  et ainsi

$$\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \boldsymbol{\Omega} \text{ avec } \boldsymbol{\Omega} = \frac{1}{1-\rho^2} \begin{pmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \rho^{n-1} & \rho^{n-2} & \dots & 1 \end{pmatrix}$$

# Régression Linéaire

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \text{ où } \mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}, \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2\boldsymbol{\Omega}.$$

L'estimateur des MCO, s'écrit toujours  $\hat{\boldsymbol{\beta}}^{\text{MCO}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$  et

$$\mathbb{E}(\hat{\boldsymbol{\beta}}^{\text{MCO}}) = \boldsymbol{\beta} \quad \text{et} \quad \text{Var}(\hat{\boldsymbol{\beta}}^{\text{MCO}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\Omega} \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Soit  $\hat{\sigma}_{\text{MCO}}^2 = \|\hat{\boldsymbol{\varepsilon}}\|/(n-p)$  alors  $\mathbb{E}\hat{\sigma}_{\text{MCO}}^2 = \text{tr}(\mathcal{P}_{\mathbf{X}^\perp} \boldsymbol{\Omega})/(n-p) \neq \sigma^2$  (en général).

## Régression Linéaire

- ▶  $\hat{\beta}^{\text{MCO}}$  reste un estimateur sans biais, donc la lecture des coefficients estimés reste pertinente même en présence d'un bruit coloré.
- ▶ Ceci est confirmé: on pourrait montrer (en rajoutant quelques hypothèses) que  $\hat{\beta}^{\text{MCO}}$  est un estimateur consistant de  $\beta$ .
- ▶ En revanche,  $\sigma^2$  n'est pas correctement estimée, et par conséquence  $\text{Var}(\hat{\beta}^{\text{MCO}})$  n'est pas correctement estimée!
- ▶ Ceci signifie que la lecture des erreurs standard n'est pas pertinente; les IC , RC , tests d'hypothèses ne tenant pas compte du bruit coloré sont donc (a priori) sans intérêt et dangereux.
- ▶ certaines variables peuvent paraître significatives alors qu'elles ne le sont pas (et inversement): il faut remédier à cette situation!

- ▶ On supposera dans un premier temps que  $\Omega$  est connue, et notons  $\Omega^{-1/2}$  sa racine carré inverse (qui existe car  $\Omega > 0$ ).
- ▶ On construit le modèle

$$\underbrace{\Omega^{-1/2}\mathbf{Y}}_{:=\mathbf{Y}'} = \underbrace{\Omega^{-1/2}\mathbf{X}}_{:=\mathbf{X}'}\boldsymbol{\beta} + \underbrace{\Omega^{-1/2}\boldsymbol{\varepsilon}}_{:=\boldsymbol{\varepsilon}'}.$$

- ▶ Il est clair que le modèle  $\mathbf{Y}' = \mathbf{X}'\boldsymbol{\beta} + \boldsymbol{\varepsilon}'$  est un modèle linéaire homoscédastique car
  - ▶  $\mathbf{X}'$  est de plein rang!
  - ▶  $\text{Var}(\boldsymbol{\varepsilon}') = \text{Var}(\Omega^{-1/2}\boldsymbol{\varepsilon}) = \Omega^{-1/2}\text{Var}(\boldsymbol{\varepsilon})\Omega^{-1/2} = \sigma^2\mathbb{I}_n$ .

On appelle estimateur des moindres carrés généralisés l'estimateur  $\hat{\boldsymbol{\beta}}^{\text{MCG}}$  égal à l'estimateur des MCO du modèle  $\mathbf{Y}' = \mathbf{X}'\boldsymbol{\beta} + \boldsymbol{\varepsilon}'$ . Ainsi

$$\hat{\boldsymbol{\beta}}^{\text{MCG}} = (\mathbf{X}'^{\top}\mathbf{X}')^{-1}\mathbf{X}'^{\top}\mathbf{Y}' = (\mathbf{X}^{\top}\Omega^{-1}\mathbf{X})^{-1}\mathbf{X}^{\top}\Omega^{-1}\mathbf{Y}.$$



## Régression Linéaire

- Conséquence du théorème de Gauss-Markov:  $\hat{\beta}^{\text{MCG}}$  est l'estimateur linéaire sans biais de variance minimale du modèle  $\mathbf{Y}' = \mathbf{X}'\beta + \varepsilon'$ ;  $\hat{\beta}^{\text{MCO}}$  étant un autre estimateur linéaire sans biais de  $\beta$

$$\text{Var}(\hat{\beta}^{\text{MCG}}) \leq \text{Var}(\hat{\beta}^{\text{MCO}}).$$

- Conséquence du théorème de Gauss-Markov:  $\hat{\beta}^{\text{MCG}}$  est l'estimateur linéaire sans biais de variance minimale du modèle  $\mathbf{Y}' = \mathbf{X}'\beta + \varepsilon'$ ;  $\hat{\beta}^{\text{MCO}}$  étant un autre estimateur linéaire sans biais de  $\beta$

$$\text{Var}(\hat{\beta}^{\text{MCG}}) \leq \text{Var}(\hat{\beta}^{\text{MCO}}).$$

## Régression Linéaire

Supposons  $\mathbf{\Omega} = \text{diag}(\pi_i^2, i = 1, \dots, n)$ , on peut montrer que la procédure des MCG est une procédure de MC pondérés, i.e.

$$\hat{\boldsymbol{\beta}}^{\text{MCG}} = \text{argmin} f(\boldsymbol{\beta}), \quad f(\boldsymbol{\beta}) = \|\mathbf{\Omega}^{-1/2}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})\|^2 = \sum_{i=1}^n w_i (Y_i - \mathbf{x}_i' \boldsymbol{\beta})^2$$

avec  $w_i = 1/\pi_i^2$ .